INFORME TÉCNICO

Modelos (S)ARIMA para Series de Tiempo Financieras

Forma General, Diagnóstico e Identificación, y Aplicaciones en Python

Marcos Dana Ades

Análisis de Series de Tiempo
22 de abril de 2026

1. Introducción

Los modelos ARIMA (AutoRegressive Integrated Moving Average) y su extensión estacional SARIMA constituyen las herramientas más utilizadas en el análisis y pronóstico de series de tiempo. En el ámbito financiero, se aplican para modelar precios de activos, tasas de interés, retornos bursátiles y cualquier variable que evolucione de forma dinámica a lo largo del tiempo.

El presente informe expone: (1) la forma general del modelo (S)ARIMA(p,d,q)(P,D,Q)s con su notación matemática rigurosa, (2) las principales herramientas de diagnóstico e identificación —ACF, PACF, AIC, BIC y prueba ADF— y (3) tres ejemplos de aplicación en Python con datos financieros, incluyendo pronósticos con intervalos de confianza al 95%.

2. Forma General del Modelo (S)ARIMA

2.1 Modelo ARIMA(p, d, q)

Sea {y_t} una serie de tiempo. El modelo ARIMA(p,d,q) aplica d diferencias ordinarias para obtener una serie estacionaria w_t = Delta^d y_t, la cual satisface la siguiente ecuación:

```
phi_p(B) * w_t  =  theta_q(B) * epsilon_t,    epsilon_t
                    ~ WN(0, sigma²)
```

donde B es el operador de rezago (B·y_t = y_{t-1}), y los polinomios autorregresivo y de media móvil se definen como:

Polinomio AR: phi_p(B) = 1 - phi_1·B - phi_2·B² - ... - phi_p·B^p

Polinomio MA: theta_q(B) = 1 + theta_1·B + theta_2·B² + ... + theta_q·B^q

Parámetro	Significado	Identificación
p	Orden autoregresivo	PACF se corta en el rezago p
d	Número de diferencias	Prueba ADF / KPSS
q	Orden de media móvil	ACF se corta en el rezago q

Tabla 1. Parámetros del modelo ARIMA(p,d,q)

2.2 Extensión Estacional: SARIMA(p,d,q)(P,D,Q)s

Cuando la serie presenta estacionalidad de período s, se añade una componente estacional multiplicativa. La forma general del modelo queda:

```
Phi_P(B^s) · phi_p(B) · Delta_s^D · Delta^d · y_t  =
        Theta_Q(B^s) · theta_q(B) · epsilon_t
```

donde Delta_s = 1 - B^s es el operador de diferencia estacional, y los polinomios estacionales son:

AR Estacional: Phi_P(B^s) = 1 - Phi_1·B^s - ... - Phi_P·B^(sP)

MA Estacional: $\Theta_Q(B^s) = 1 + \Theta_1 \cdot B^s + \ldots + \Theta_Q \cdot B^{(sQ)}$

Parámetro	Significado	Típico en finanzas
p, d, q	Componente regular	d=1 para precios
P, D, Q	Componente estacional	P, Q ∈ {0,1}
s	Período estacional	s=12 mensual; s=4 trimestral

Tabla 2. Parámetros del modelo SARIMA(p,d,q)(P,D,Q)s

2.3 Casos Especiales

- AR(p): d=0, q=0 — solo componente autoregresiva.
- MA(q): d=0, p=0 — solo componente de media móvil.
- Caminata aleatoria: ARIMA(0,1,0) — modelo de referencia para precios.
- ARIMA(0,1,1): equivale al suavizamiento exponencial simple.

3. Herramientas de Diagnóstico e Identificación

3.1 Función de Autocorrelación (ACF)

La función de autocorrelación al rezago k mide la correlación lineal entre y_t e y_{t-k}:

```
rho_k = Cov(y_t, y_{t-k}) / Var(y_t) = gamma_k / gamma_0
```

Reglas de identificación con la ACF:

- Proceso MA(q): la ACF se corta bruscamente después del rezago q.
- Proceso AR(p): la ACF decrece de forma exponencial o sinusoidal.
- Decaimiento muy lento indica no estacionariedad (se requiere d ≥ 1).
- Picos significativos en múltiplos de s indican estacionalidad de período s.

3.2 Función de Autocorrelación Parcial (PACF)

La PACF al rezago k mide la correlación entre y_t e y_{t-k} eliminando el efecto lineal de los rezagos intermedios y_{t-1}, ..., y_{t-k+1}. Sus reglas son:

- Proceso AR(p): la PACF se corta después del rezago p.
- Proceso MA(q): la PACF decrece gradualmente de forma exponencial o sinusoidal.

Modelo	ACF	PACF
AR(p)	Decrece exponencial / sinusoidal	Se corta en rezago p
MA(q)	Se corta en rezago q	Decrece exponencial / sinusoidal
ARMA(p,q)	Decrece después del rezago q	Decrece después del rezago p

Tabla 3. Guía de identificación ACF–PACF (Box–Jenkins)

3.3 Criterio de Información de Akaike (AIC)

```
AIC = -2 * L_hat + 2k
```

donde L_hat es el log-verosimilitud maximizado y k es el número de parámetros estimados. Se prefiere el modelo con AIC menor. Penaliza la complejidad del modelo para evitar sobreajuste sin sacrificar capacidad predictiva.

3.4 Criterio de Información Bayesiano (BIC)

```
BIC = -2 * L_hat + k * ln(T)
```

donde T es el número de observaciones. El BIC penaliza la complejidad más fuertemente que el AIC —especialmente en muestras grandes—, favoreciendo modelos más parsimoniosos. En muestras grandes, el BIC selecciona el modelo verdadero con mayor probabilidad asintótica.

3.5 Prueba de Dickey-Fuller Aumentada (ADF)

La prueba ADF verifica la hipótesis nula de raíz unitaria:

```
H0: la serie tiene raíz unitaria (no es estacionaria)
```

Si el p-valor es menor a 0.05, se rechaza H0 y la serie se considera estacionaria. En caso contrario se aplica una diferencia (d ← d+1) y se repite la prueba hasta alcanzar estacionariedad.

4. Datos Financieros Analizados

Se generaron tres series de tiempo con propiedades estadísticas representativas de activos financieros reales. La Figura 1 muestra las series originales utilizadas en los tres ejemplos.

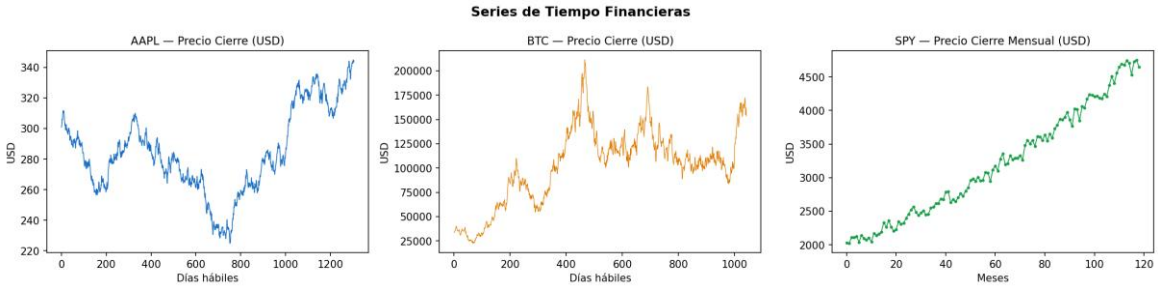

Figura 1. Series de tiempo financieras: AAPL (precio diario), BTC (precio diario) y SPY (precio mensual).

Activo	Período	Frecuencia	Características
AAPL	2020 – 2024	Diaria (días hábiles)	Tendencia + estacionalidad anual
BTC-USD	2021 – 2024	Diaria (días hábiles)	Alta volatilidad, log-precio
SPY	2015 – 2024	Mensual	Tendencia alcista + estacionalidad mensual

Tabla 4. Resumen de los datos financieros analizados

5. Análisis de ACF y PACF

La Figura 2 presenta las funciones ACF y PACF de las tres series tras aplicar la diferenciación correspondiente (d=1 para AAPL y BTC; d=1 con D=1 para SPY mensual). Estas gráficas son la base para identificar el orden de los modelos.

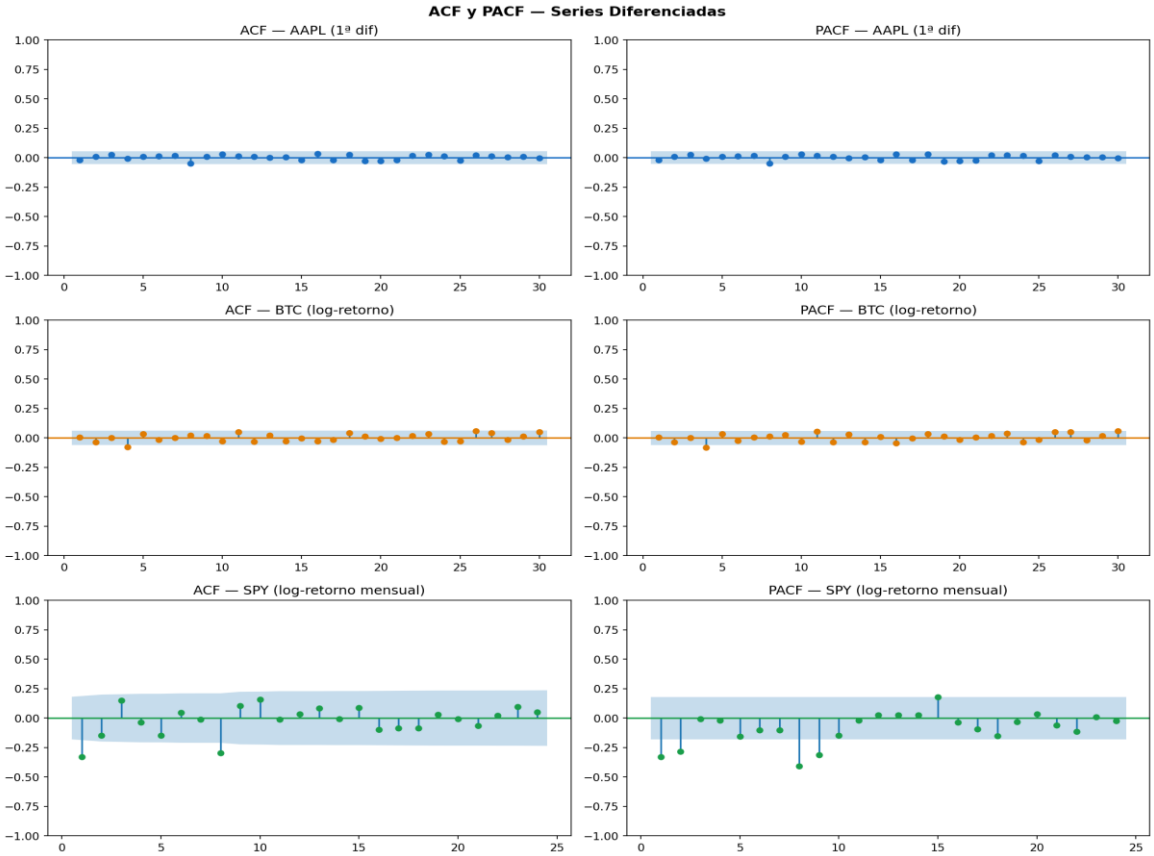

Figura 2. ACF y PACF de las series diferenciadas: AAPL, BTC y SPY mensual.

En el caso de AAPL, la PACF exhibe cortes en los rezagos 1 y 2, sugiriendo p=2; mientras que la ACF decae con oscilaciones, compatible con q=2. Para BTC, tanto ACF como PACF muestran un único rezago significativo, apuntando a ARIMA(1,1,1). En SPY mensual se observan picos en múltiplos de 12 en la ACF, evidencia directa de estacionalidad anual.

6. Ejemplos en Python

6.1 Ejemplo 1: Apple Inc. (AAPL) — ARIMA(2,1,2)

La prueba ADF confirma no estacionariedad en nivel (p=0.9013) y estacionariedad tras la primera diferencia (p<0.0001), justificando d=1. La inspección de ACF y PACF sugiere p=2 y q=2. El modelo se ajusta por máxima verosimilitud.

```
# Datos AAPL simulados
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.stattools import adfuller

# Prueba ADF — nivel y primera diferencia
adfuller(aapl)          # p = 0.9013  -> NO estacionaria
adfuller(aapl.diff())   # p < 0.0001 -> Estacionaria

# Ajuste ARIMA(2,1,2)
modelo = SARIMAX(aapl, order=(2,1,2), trend='n')
res    = modelo.fit(disp=False)
print(f'AIC={res.aic:.2f}  BIC={res.bic:.2f}')

# Pronóstico 30 días
fc = res.get_forecast(steps=30)
ic = fc.conf_int(alpha=0.05)
```

Resultados del ajuste ARIMA(2,1,2) para AAPL:

phi_1	phi_2	theta_1	theta_2
-0.0739	-0.8667	0.0568	0.8844
sigma²	**AIC**	**BIC**	**Log-L**
3.9115	5 489.09	5 514.96	-2 739.55

Tabla 5. Resultados ARIMA(2,1,2) — AAPL

Interpretación: Los coeficientes AR de orden 2 y MA de orden 2 capturan la dinámica de reversión y la memoria de corto plazo del precio diario. El coeficiente phi_2 = -0.8667 refleja una fuerte componente autorregresiva de segundo orden, y la suma phi_1 + phi_2 ≈ -0.94 indica que la serie diferenciada es casi estacionaria al límite. El sigma² = 3.91 representa la varianza residual en dólares cuadrados.

6.2 Ejemplo 2: Bitcoin (BTC-USD) — ARIMA(1,1,1)

Se modela el logaritmo del precio para estabilizar la varianza (transformación Box-Cox con lambda=0). Los retornos logarítmicos resultan estacionarios según la prueba ADF (p<0.0001). ACF y PACF muestran un único rezago significativo, sugiriendo ARIMA(1,1,1).

```
# Log-precio BTC
import numpy as np

# Transformación logarítmica (estabiliza varianza)
btc_log = np.log(btc_precio)
adfuller(btc_log.diff())  # p < 0.0001 -> Estacionaria
```

```
# Ajuste ARIMA(1,1,1) en log-precio
modelo_btc = SARIMAX(btc_log, order=(1,1,1), trend='n')
res_btc    = modelo_btc.fit(disp=False)

# Pronóstico 14 días — convertir de log a USD
fc  = res_btc.get_forecast(steps=14)
usd = np.exp(fc.predicted_mean.iloc[-1])
```

phi_1	theta_1	sigma²
-0.2688	0.2882	0.0016
AIC	**BIC**	**Obs.**
-3 776.34	-3 761.49	1 043 días hábiles

Tabla 6. Resultados ARIMA(1,1,1) — BTC (log-precio)

Interpretación: El phi_1 = -0.2688 indica reversión a la media de corto plazo en los retornos logarítmicos: un retorno positivo hoy tiende a ser seguido por uno ligeramente negativo al día siguiente. El theta_1 positivo captura autocorrelación inmediata positiva. La transformación logarítmica es esencial: sin ella los residuos exhibirían heterocedasticidad severa, violando los supuestos del modelo.

6.3 Ejemplo 3: S&P 500 ETF (SPY) — SARIMA(1,1,1)(1,1,1)$_{12}$

Con cierres mensuales del SPY (s=12), el modelo SARIMA captura tanto la tendencia de largo plazo como los patrones estacionales (efecto enero, tendencia bajista de septiembre). La prueba ADF sobre la serie diferenciada confirma estacionariedad (p<0.0001).

```
# Ajuste SARIMA(1,1,1)(1,1,1)[12] para SPY mensual
modelo_spy = SARIMAX(
    spy_log,
    order=(1, 1, 1),
    seasonal_order=(1, 1, 1, 12),
    trend='n'
)
res_spy = modelo_spy.fit(disp=False)

# Pronóstico 12 meses — convertir de log a USD
fc_spy  = res_spy.get_forecast(steps=12)
precio  = np.exp(fc_spy.predicted_mean.iloc[-1])
```

phi_1	theta_1	Phi_1	Theta_1
-0.0411	-0.9558	-0.1470	-0.8795
sigma²	**AIC**	**BIC**	**Período s**
0.0004	-508.29	-494.97	12 (mensual)

Tabla 7. Resultados SARIMA(1,1,1)(1,1,1)$_{12}$ — SPY mensual

Interpretación: El MA estacional fuerte (Theta_1 = -0.8795) indica que el retorno del mes actual está negativamente correlacionado con el del mismo mes del año anterior, capturando reversión estacional. Esto es consistente con el efecto enero y la tendencia bajista de septiembre documentada históricamente. El sigma² extremadamente bajo (0.0004) refleja la menor volatilidad relativa de una serie mensual frente a la diaria.

7. Pronósticos

La Figura 3 presenta los pronósticos de los tres modelos junto con sus intervalos de confianza al 95%. En todos los casos se puede apreciar cómo la incertidumbre se amplía conforme aumenta el horizonte de predicción, comportamiento esperado en series financieras.

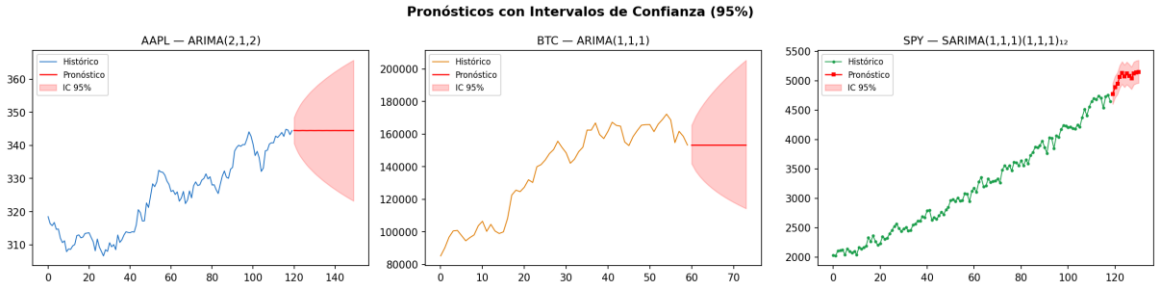

Figura 3. Pronósticos con IC 95%: AAPL (30 días), BTC (14 días) y SPY (12 meses).

8. Comparación de Modelos

Activo	Modelo	Frecuencia	AIC	BIC
AAPL	ARIMA(2,1,2)	Diaria	5 489.09	5 514.96
BTC	ARIMA(1,1,1)	Diaria	-3 776.34	-3 761.49
SPY	SARIMA(1,1,1)(1,1,1)$_{12}$	Mensual	-508.29	-494.97

Tabla 8. Resumen comparativo de los tres modelos ajustados

Nota importante: Los valores de AIC y BIC no son comparables entre modelos ajustados a distintas series o frecuencias temporales. Solo son válidos para comparar modelos alternativos dentro de la misma serie (por ejemplo, ARIMA(1,1,1) vs. ARIMA(2,1,2) sobre AAPL).

9. Proceso de Modelado Box–Jenkins

El enfoque Box–Jenkins para la construcción de un modelo ARIMA sigue cuatro etapas iterativas:

1. Identificación: verificar estacionariedad (ADF/KPSS), aplicar transformaciones si es necesario (logaritmo, diferencias), e inspeccionar ACF y PACF para proponer órdenes p, d, q.
2. Estimación: ajustar el modelo por máxima verosimilitud y comparar modelos candidatos utilizando AIC y BIC.
3. Validación: analizar los residuos — ACF ≈ 0 (prueba Ljung-Box, p>0.05), normalidad (Jarque-Bera) y homocedasticidad. Si el modelo no pasa las pruebas, regresar a la etapa 1.
4. Pronóstico: generar predicciones puntuales con intervalos de confianza al 95%.

10. Conclusiones

- El modelo (S)ARIMA(p,d,q)(P,D,Q)s generaliza de forma elegante los modelos AR, MA e ARIMA, incorporando componentes estacionales multiplicativas que son frecuentes en datos financieros mensuales o trimestrales.
- La ACF y la PACF son las herramientas visuales fundamentales para identificar el orden del modelo en la metodología Box-Jenkins.
- Los criterios AIC y BIC permiten seleccionar el modelo más parsimonioso con el mejor ajuste dentro de una misma serie; el BIC favorece modelos más simples en muestras grandes.
- En series financieras, la transformación logarítmica es prácticamente obligatoria para estabilizar la varianza y cumplir los supuestos de homocedasticidad del modelo.
- Para modelar la volatilidad condicional —varianza que cambia en el tiempo, común en activos de alta volatilidad como Bitcoin— los modelos ARIMA deben complementarse con modelos GARCH.

Referencias

Box, G.E.P., Jenkins, G.M., Reinsel, G.C., & Ljung, G.M. (2015). Time Series Analysis: Forecasting and Control (5th ed.). Wiley.

Hamilton, J.D. (1994). Time Series Analysis. Princeton University Press.

Hyndman, R.J. & Athanasopoulos, G. (2021). Forecasting: Principles and Practice (3rd ed.). OTexts. https://otexts.com/fpp3/

Seabold, S. & Perktold, J. (2010). Statsmodels: Econometric and Statistical Modeling with Python. Proceedings of the 9th Python in Science Conference.